Al aumentar la profundidad de la red a una topología 4x3x3x3x3, el error no disminuyó de forma efectiva; por el contrario, el aprendizaje se estancó. En la implementación de Keras, la pérdida inició e 0.3063 y apenas descendió 0.2042 tras 500 épocas de entrenamiento. Este estancamiento de la curva de pérdida se observa tanto en la implementación manual con Numpy como en el modelo secuencial de TensorFlow.

Aunque ambas redes exhiben la misma falta de convergencia, pueden presentar ligeras diferencias en la suavidad de la curva. Esto se debe a los métodos de implementación: el código manual actualiza los pesos puramente de forma e inicializa los pesos de forma uniforme entre -0.5 y 0.5. Por su parte, Keras incluye optimizaciones internas, diferentes algoritmos por defecto para la inicialización de los pesos y cálculos vectorizados subyacentes. En cuanto a la velocidad, Numpy fue más rapido (15.6s vs 25.2s).

El estancamiento ocurre porque al usar solo activaciones sigmoides en cuatro capas densas.