Repoite - Ejercicio 8

1.. Porque Q-learning es un algoritmo off-policy, lo que significa que actualiza sus valores asumiendo qué en el futuro siempre tomaremos la mejor acción posible (la acción greedy). Como bajo una política 100% determista sabemos que no vamos a "resbalar" hacia el acantilado por accidente, la ruta más corto resulta ser la más directa: pegarnos al borde. Ese camino toma exactamente 13 pasos, y como cada paso nos cuesta -1, el mejor retorno que podemos obtener es -13.

2.. Esto pasa por la exploración. Durante el entrenamiento usamos una política ε-greedy con $\varepsilon = 0.1$, lo que nos obliga a tomar acción al azar el 10% de las veces. Como la política que estamos aprendiendo nos lleva caminando justo por el borde de la fila 2, es muy probable que uno de estos movimientos al azar nos haga dar un paso al sur y nos tire al acantilado. Ese castigo de -100 arrastra el promedio de la recompensa hacia abajo durante el entremiento, a diferencia de la evaluación final donde apagamos la exploración ($\varepsilon = 0$) y ya no nos caemos.

3.. Cuando el agente cae al acantilado, el estado siguiente S' es el estado inicial S (la coordenada (3,0)). En la fórmula de actualización no lo tratamos como un estado terminal (donde el valor futuro sería cero) porque, de acuerdo con las reglas de esta versión de entorno, caerse no termina el episodio. Simplemente nos teletransporta de nuevo al inicio. Por lo tanto, el agente todavía tiene que contemplar el costo que le va a tomar llegar a la meta desde ese punto S.